

Задача усвоения данных на примере системы Лоренца

Кудяков Дамир (группа 216)
Факультет ВМК МГУ

Март 2026

Содержание

1	Введение	3
2	Постановка задачи ассимиляции данных	3
3	Система дифференциальных уравнений Лоренца	5
4	Обзор методов ассимиляции	6
4.1	Метод последовательных правок (SCM-метод)	6
4.2	Метод подгонки (nudging)	6
4.3	Трёхмерное вариационное усвоение (3D-Var)	7
4.4	Четырёхмерное вариационное усвоение (4D-Var)	8
4.4.1	Классический 4D-Var	8
4.4.2	Слабая формулировка 4D-Var (weak constraint) . . .	10
5	Численный эксперимент	10
5.1	Начальные данные	10
5.2	Реализация	11
5.3	Результат	12
6	Заключение	13
	Список литературы	13

1 Введение

Люди издревле мечтали всецело познать природу, описать весь мир вдоль и поперёк. С каждым столетием улучшались как инструменты для познания окружение, так и теоретические аспекты. Попытка человека обуздать всё не обошла и погоду. Развитые сети метеостанций, на которых измеряются всевозможные параметры (температура, влажность, давление, скорость и направление ветра и т.д.) появились в XIX веке. Прогнозировать будущие погодные условия приходилось синоптикам, анализирующим бесчисленные наборы карт, с нанесёнными на них данными с точек по всему миру. В начале XX века возникла идея численного прогнозирования погоды на основе системы дифференциальных уравнений, описывающих гидродинамику атмосферы. Бурное развитие вычислительных систем во второй половине столетия обеспечило возможность быстро рассчитывать всевозможные математические модели, которые ещё совсем недавно были на бумаге. Закономерным итогом этого стало развитие моделей численного прогнозирования погоды, которые дали огромный прорыв в метеорологии.

Тем не менее, даже на сегодняшний день, лучшие модели прогнозирования погоды не способны дать адекватный прогноз условий более чем на 2 недели. Ошибки измерительных приборов и неточности математической модели не позволяют предсказывать погоду на большие сроки. В ближайшее время эта проблема решена не будет, если решение вообще существует. Однако это нисколько не мешает развивать науку, в частности улучшать математический аппарат в метеорологии.

2 Постановка задачи ассимиляции данных

Зададим математическую модель, описывающую эволюцию гидродинамической системы (атмосферной, океанской или совместной):

$$\begin{cases} \frac{dx}{dt} = M(x, t) & t > 0 \\ x|_{t=0} = x_0 \end{cases} \quad (2.1)$$

Опишем объекты, входящие в систему уравнений.

x - вектор состояния модели (поле). Фактически этот вектор содержит состояние модельной системы в каждой точке земного шара, где эта модель задана. В задачах ассимиляции данных привязка к пространству в явном виде не используется. Отметим, что в реальных моделях размерность вектора состояния может достигать порядка 10^9 .

x_0 - вектор начального состояния.

M - динамический оператор модели. Он определяет эволюцию системы во времени. В общем случае он является нелинейным и детерминированным.

Вектор наблюдений задаётся следующей функцией:

$$y^0(t) = H(x^t) + \varepsilon \quad (2.2)$$

где:

x^t - вектор-функция истинного поля.

H - оператор наблюдений, отображающий пространство состояния в пространство наблюдений. В общем случае он может быть нелинейным. Например, в пространстве состояний может быть определена температура верхней границы облачности, а в пространстве наблюдений - некоторый внутренний параметр спутника, который снимает земной шар.

ε - функция ошибок (шум)

При дискретизации указанной модели, (2.1) переходит в (2.3), а (2.2) в (2.4):

$$x(t_{i+1}) = M_i(x(t_i)) \quad (2.3)$$

$$y_i^0 = H_i(x^t(t_i)) + \varepsilon_i \quad (2.4)$$

$x(t_i)$ - вектор состояния размерности n

i - номер шага по времени.

M_i - разностный оператор динамики вектора состояния. В частности, он зависит от выбора разностной схемы.

H_i - оператор наблюдений в момент времени $t = t_i$

ε_i - функция ошибки

y_i^0 - вектор наблюдений. Он имеет размерность p_i . Для большинства практических задач верно $p_i \ll n$.

Описав основные объекты, переходим непосредственно к задаче об усвоении данных: требуется найти начальное условие x^a , которое бы удовлетворяло системе (2.1), и в то же время вектор $H(x)$ был бы близок к $y^0(t)$. Понятие близости векторов $y^0(t)$ и $H(x)$ зависит от конкретного метода усвоения данных, и как станет видно в последующих разделах, это понятие неоднократно менялось с развитием задачи.


3 Система дифференциальных уравнений Лоренца

Небезызвестной является система дифференциальных уравнений Лоренца (1963), служащая примером детерминированного хаоса:

$$\begin{cases} \frac{dx}{dt} = \sigma(y - x) \\ \frac{dy}{dt} = x(\rho - z) - y \\ \frac{dz}{dt} = xy - \beta z \end{cases}$$

где σ , ρ и β - параметры системы.

Главной особенностью этой системы является необычное поведение при параметрах $\sigma = 10$, $\rho = 28$, $\beta = 8/3$. Если в качестве начального вектора $v_0 = (x_0, y_0, z_0)^T$ выбрать значение, близкое к $(0, 0, 0)^T$ (сам вектор θ является стационарной точкой, поэтому не подходит), например, $v_0 = (1, 1, 1)^T$, то появится аттрактор Лоренца - некоторое компактное подмножество фазового пространства решения системы, в котором находятся (или стремится к нему при $t \rightarrow \infty$) траектории решения из некоторой его окрестности.



Если визуализировать аттрактор Лоренца, то можно будет разглядеть силуэт бабочки - символ хаоса.

Данная система похожа на реальную атмосферную систему в том смысле, что даже при небольших отклонениях в начальных данных, разница в траекториях возрастает крайне быстро. В дальнейшем, на примере этой системы будет рассмотрена задача усвоения данных.

Рис. 1: Аттрактор Лоренца, полученный при начальном векторе $(1, 1, 1)^T$ методом Рунге-Кутты 4-го порядка

4 Обзор методов ассимиляции

В данном разделе будет проведён обзор для каждого из методов усвоения данных, рассматриваемых в данном сочинении.

В различных методах будет использоваться понятие вектора фона x^b , который формально определён следующим образом:

$$x^b = x^t + \varepsilon_b$$

4.1 Метод последовательных правок (SCM-метод)

Метод был предложен Крессманом в 1959 году и представляет собой итерационный алгоритм уточнения начального вектора состояния:

$$x^{k+1} = x^k + W(y^0 - H(x^k)), \quad k = 0, 1, \dots, K - 1 \quad (4.1.1)$$

где:

k - номер итерации, K - количество итераций

$x^0 = x^b$ - начальное приближение, где x^b - вектор фона

H - оператор наблюдений

W - весовой оператор, в общем случае зависящий от номера итерации k . Фактически является единственным параметром метода.

Результатом метода является вектор $x^a = x^K$. Матрица W подбирается эмпирическим путём.

Основной недостаток метода - алгоритм никак не учитывает ошибки наблюдений [1].

4.2 Метод подгонки (nudging)

Является обобщением метода последовательных правок. Предложен Хоуком в 1976 году.

В методе рассматривается система (2.1), в которой добавляется корректирующее слагаемое вида (4.1.1):

$$\begin{cases} \frac{dx}{dt} = M(x, t) + W(y^0 - H(x)), & t \in [0, T] \\ x|_{t=0} = x_0, \end{cases} \quad (4.2.1)$$

Основным улучшением этого метода является корректировка вектора не в одной конкретной точке, а попытка улучшить траекторию в целом. Недостаток, связанный с доверием наблюдениям сохранился.

4.3 Трёхмерное вариационное усвоение (3D-Var)

Метод трёхмерного вариационного усвоения (3D-Var) основан на минимизации следующего функционала, зависящего от вектора начального состояния:

$$J(x) = \frac{1}{2}(x - x^b)^T C_1 (x - x^b) + \frac{1}{2}(Hx - y^0)^T C_2 (Hx - y^0) = J_b(x) + J_0(x) \quad (4.3.1)$$

где $J_b(x) = \frac{1}{2}(x - x^b)^T C_1 (x - x^b)$ и $J_0(x) = \frac{1}{2}(Hx - y^0)^T C_2 (Hx - y^0)$ - квадратичные функционалы стоимости, отвечающие за ошибку фона и ошибку наблюдений соответственно.

Замечание: Здесь и далее будем полагать, что оператор наблюдений H является линейным.

Замечание: каждое из слагаемых функционала $J(x)$ представляет собой скалярное произведение вида $(C_i v_i, v_i)$, однако запись (4.3.1) предполагает работу в конкретном базисе, причём матрица Грама $G = E$, поэтому данная матрица в записи функционала опускается.

Векторы $\delta^b = x - x^b$ и $\delta^0 = Hx - y^0$ представляют собой отклонения вектора начального состояния от вектора фона и вектор наблюдений соответственно. В связи с этим зачастую весовые матрицы определяются как $C_1 = B^{-1}$ и $C_2 = R^{-1}$ [2], где $B = \mathbb{E}(\varepsilon_b \varepsilon_b^T)$ и $R = \mathbb{E}(\varepsilon \varepsilon^T)$ - ковариационные матрицы ошибок фона и наблюдений [1].

Таким образом, функционал $J_b(x)$ оценивает стоимость ошибки фона, а функционал $J_0(x)$ стоимость ошибки наблюдений.

Для нахождения минимума функционала $J(x)$ найдём его градиент [4, 7]:

$$\nabla J = \nabla J_b + \nabla J_0 = B^{-1}(x - x^b) + H^T R^{-1}(Hx - y^0) \quad (4.3.2)$$

Выражая x , получаем выражение для вектора x^a , задающий стационарную точку функционала:

$$x^a = (B^{-1} + H^T R^{-1} H)^{-1} (B^{-1} x^b + H^T R^{-1} y^0) \quad (4.3.3)$$

Заметим, что оператор H является линейным, поэтому вектор x^a из (4.3.3) задаётся однозначно [4]. Учитывая то, что матрицы B и R являются ковариационными и имеют обратные, заключаем, что они положительно определены. Как итог получаем, что минимум $J(x)$ достигается в x^a .

Рассмотрим простейший частный случай, где $H = I$ (тождественный оператор), $B = \sigma_b^2 I$, $R = \sigma_0^2 I$.

$$x^a = \frac{\frac{x^b}{\sigma_b^2} + \frac{y^0}{\sigma_0^2}}{\frac{1}{\sigma_b^2} + \frac{1}{\sigma_0^2}} = \frac{\lambda_b x^b + \lambda_0 y^0}{\lambda_b + \lambda_0} = \kappa x^b + (1 - \kappa) y^0 \quad (4.3.4)$$

где $\lambda_b = \frac{1}{\sigma_b^2}$, $\lambda_0 = \frac{1}{\sigma_0^2}$, $\kappa = \frac{\lambda_b}{\lambda_b + \lambda_0}$, $\kappa \in (0, 1)$

Если $\sigma_b \ll \sigma_0$ получаем, что $\kappa \approx 1$ и $x^a \approx x^b$. Если верно $\sigma_0 \ll \sigma_b$ получаем, что $\kappa \approx 0$ и $x^a \approx y^0$. Таким образом, коэффициент κ показывает степень доверия к фону и наблюдениям. Он же является единственным параметром метода, так как абсолютные значения σ_b^2 и σ_0^2 не влияют на положение минимума функционала $J(x)$.

Основным достоинством метода является явный учёт ошибок наблюдений, описанный в матрице R .

Главной же проблемой может явиться поиск минимума функционала $J(x)$. Во-первых, в случае нелинейности оператора наблюдений H минимум может оказаться неединственным [4]. Помимо этого, вспомним, что размерность вектора x очень большая (порядка 10^9), а значит и матрица B тоже будет очень большой. В связи с этим в явном виде вычислять выражение (4.3.3) будет крайне вычислительно затратно. Поэтому минимум зачастую ищется с помощью методов оптимизации [4].

4.4 Четырёхмерное вариационное усвоение (4D-Var)

Развитием вариационного подхода к ассимиляции данных стало пространственно-временное усвоение данных. Алгоритмы и математический аппарат данного метода значительно усложняется из-за необходимости решения сопряжённых уравнений и построения линеаризованных моделей [3].

4.4.1 Классический 4D-Var

Как и в методе 3D-Var, мы имеем функционал $J(x)$, который требуется минимизировать, но в отличие от предыдущего метода, слагаемое, отвечающее наблюдениям, берётся не в один конкретный срок, а на некотором интервале.

$$J(x) = \frac{1}{2}(C_1(x^0 - x^b), (x^0 - x^b)) + \frac{1}{2} \int_0^T (C_2(Hx - y^0), (Hx - y^0)) dt \quad (4.4.1.1)$$

Замечание: Если в 3D-Var искался вектор начального состояния и функционал зависел только от него, то в 4D-Var функционал зависит от x^t в целом. При этом поиск всё равно ведётся не по вектор-функциям, а

по вектору начального состояния, так как из начального условия $x^0 = x^a$ и системы (2.1) будет однозначно определяться вся функция x^t .

Пусть δx_0 - некоторое возмущение вектора начального состояния, а δx (зависит от времени t) - возмущение в конкретный момент времени, порождённое возмущением δx_0 .

По определению градиента [2]:

$$J'\delta x_0 = (C_1(x^0 - x^b), \delta x_0) + \int_0^T (C_2(Hx - y^0), H\delta x)dt \quad (4.4.1.2)$$

Важно, что для δx выполняется TLM (tangent linear model):

$$\frac{d\delta x}{dt} = M'(x, t)\delta x, \quad \delta x|_{t=0} = \delta x_0 \quad (4.4.1.3)$$

Далее переходим к задаче, сопряжённой к TLM:

$$-\frac{dx^*}{dt} = (M'(x, t))^*x^* - p, \quad x^*|_{t=T} = \theta \quad (4.4.1.4)$$

где $p = H^*C_2(Hx - y^0)$.

Далее, из соотношения сопряжённости $\int_0^T (p, \delta x)dt = -(x^*|_{t=0}, \delta x_0)$ получаем градиент:

$$J'\delta x_0 = (C_1(x^0 - x^b), \delta x_0) + \int_0^T (p, \delta x)dt = (C_1(x^0 - x^b) - x^*|_{t=0}, \delta x_0) \quad (4.4.1.5)$$

Приведённое выше выражение позволяет вычислять необходимый градиент более эффективно, чем в случае выражения (4.4.1.2). Полагая, что $\delta x_0 \neq \theta$, получаем, что градиент нулю, если имеет место:

$$C_1(x^0 - x^b) = x^*|_{t=0} \quad (4.4.1.6)$$

В конечном счёте, условие оптимальности складывается из условий (2.1), (4.4.1.4) и (4.4.1.6) [2]:

$$\begin{cases} \frac{dx}{dt} = M(x, t) & t \in (0, T) \\ x|_{t=0} = x_0 \\ -\frac{dx^*}{dt} = (M'(x, t))^*x^* - p = H^*C_2(Hx - y^0), & x^*|_{t=T} = \theta \\ C_1(x^0 - x^b) = x^*|_{t=0} \end{cases} \quad (4.4.1.7)$$

Основным достоинством классического пространственно-временного усвоения данных является возможность уточнять начальное условие на основе ряда наблюдений на некотором временном интервале. Здесь же и возникают основные трудности метода: большие по сравнению с 3D-Var вычислительные затраты, поддержка TLM и сопряжённой к ней задачи.

4.4.2 Слабая формулировка 4D-Var (weak constraint)

Хотя и формально в системе (4.4.1.7) неизвестными являются x, x^*, x^0 , вектор-функции x, x^* однозначно определяются системой (2.1). Это называют сильной формулировкой (strong constraint). Если же не требовать строгого выполнения системы (2.1), а отхождение вектор-функции от модельной учитывать в функционале стоимости $J(x)$, то мы получаем метод 4D-Var со слабой формулировкой [1]:

$$J(x) = \frac{1}{2}(C_1(x^0 - x^b), (x^0 - x^b)) + \frac{1}{2} \int_0^T (C_2(Hx - y^0), (Hx - y^0)) dt + \frac{1}{2} \int_0^T (C_3 f, f) dt \quad (4.4.2.1)$$

где $f = \frac{dx}{dt} - M(x, t)$.

Вместо (2.1) рассматривают модифицированную систему:

$$\begin{cases} \frac{dx}{dt} = M(x, t) + f & t \in (0, T) \\ x|_{t=0} = x_0 \end{cases} \quad (4.4.2.2)$$

Таким образом, слабая формулировка 4D-Var позволяет учитывать ошибки модели $M(x, t)$, позволяя решению x, x^0 более гибко описывать будущие условия в гидродинамической системе.

5 Численный эксперимент

В данном разделе в качестве модельной гидродинамической системы рассмотрим систему Лоренца и реализуем вариационный метод усвоения данных 3D-Var для поиска оптимального начального состояния.

5.1 Начальные данные

Дана система дифференциальных уравнений на интервале $t \in [0, 100]$:

$$\begin{cases} \frac{dx_1}{dt} = \sigma(x_2 - x_1) \\ \frac{dx_2}{dt} = x_1(\rho - x_3) - x_2 \\ \frac{dx_3}{dt} = x_1x_2 - \beta x_3 \\ x|_{t=0} = x^0 = (1, 1, 1)^T \\ \sigma = 10, \quad \rho = 28, \quad \beta = 8/3 \end{cases} \quad (5.1)$$

Разделив временной интервал на $N = 10^5$ ячеек получим шаг по времени равный $T/N = 100/10000 = 0.01$.

5.2 Реализация

В качестве условно истинного поля x^t возьмём эволюцию начального условия x^0 через метод Рунге-Кутта 4-го порядка. В качестве же модели $M(x, t)$ возьмём реализацию системы через метод Рунге-Кутта 2-го порядка.

Чтобы "разогреть" систему Лоренца, мы будем рассматривать в качестве вектора начального состояния, который нам надо найти согласно задаче об усвоении данных (см. раздел 2), на момент времени $t = 50$.

Модель, использующая метод Рунге-Кутта 2-го порядка получит истинный вектор с добавленной ошибкой на момент времени $t = 45$. В дальнейшем из-за накопления ошибки вектор x^b будет отличаться от истинного.

Оператор наблюдений будет тождественным $H = I$. Ошибку в наблюдениях будем генерировать через генератор псевдослучайных чисел.

В качестве истинных матриц ковариации ошибок фона и наблюдений рассмотрим $R = B = I$.

В качестве эмпирических матриц ковариации ошибок фона и наблюдений будем рассматривать матрицы: $R = I/(1 - \kappa)$, $B = I/\kappa$.

В качестве эмпирических коэффициентов были рассмотрены $\kappa \in [0.01, 0.99]$ с шагом 0.01. Для каждого параметра κ ошибка наблюдений и фона генерировалась 1000 раз посредством генератора случайных (метод Монте-Карло) чисел с числом-затравкой 37.

Также помимо случая использования метода Рунге-Кутта 2-го порядка в модели была рассмотрена модель, использующая метод Рунге-Кутта 4-го порядка. Как станет видно далее, это влияет на то, какой выбор параметра κ является наиболее оптимальным.

5.3 Результат

Как итог, так как в истинных ковариационных матрицах параметр $\kappa \approx 0.5$, то наилучший результат был получен при одинаковом доверии к фону и наблюдениям, если в модели использовался метод Рунге-Кутты 4-го порядка.




Рис. 2: График зависимости среднего (за 1000 итераций) отклонения реального вектора от вектора, полученного усвоением данных (модель Рунге-Кутта 4-го порядка

В случае же использования в модели метода Рунге-Кутта 2-го порядка оптимальное значение параметра $\kappa \approx 0.3$, так как дополнительная ошибка, связанная с неточностью метода, не учтена в матрице ковариации B , посредством которой и генерировался вектор ошибки фона.



Рис. 3: График зависимости среднего (за 1000 итераций) отклонения реального вектора от вектора, полученного усвоением данных (модель Рунге-Кутты 2-го порядка). Вместе со смещением оптимального значения параметра κ увеличился минимум ошибки, так как из-за ухудшения модели снизилось общее качество усвоения данных

Исходный код в формате Jupyter Notebook с пояснениями выложен здесь: <https://github.com/Meteoman05/Data-Assimilation-Lorenz-63>

6 Заключение

Ассимиляция данных - мощный инструмент, который позволяет в условиях неопределённости пытаться уравнивать чаши весов наблюдения и модельную картину. Лично я уверен, что в ближайшие годы эта тема станет актуально не только для задач гидродинамики и естественных наук в целом, но и найдёт отклик в самых разных сферах человечества.

Список литературы

- [1] В. П. Шутяев. *Методы усвоения данных наблюдений в задачах физики атмосферы и океана*. ИВМ им. Г.И. Марчука РАН, 2019

- [2] Е. И. Пармузин, В. Б. Залесный. *Методы вариационного усвоения данных в моделях геофизической гидродинамики и их применение*. ИВМ им. Г.И. Марчука РАН, 2020
- [3] В.П. Дымников, В.Б. Залесный. *Основы вычислительной геофизической гидродинамики*. ИВМ им. Г.И. Марчука РАН. Геос, 2019
- [4] *Three-dimensional variational assimilation*. University of Oklahoma
URL: <https://twister.caps.ou.edu/OBAN2019/3DVAR.pdf>
- [5] *4D-Variational Data Assimilation*. University of Oklahoma
URL: <https://twister.caps.ou.edu/OBAN2019/4DVAR.pdf>
- [6] Amos S. Lawless. *Data assimilation with the Lorenz equations*. University of Reading
URL: <https://earth.esa.int/eogateway/documents/20142/3016005/EO-Summer-School-6-Ensemble-and-extended-Kalman-filters.pdf>
- [7] *Matrix Calculus*. Imperial College London
URL: <https://www.doc.ic.ac.uk/~ahanda/referencepdfs/MatrixCalculus.pdf>